Міністерство освіти і науки України
Львівський національний університет імені Івана Франка
Факультет електроніки та комп’ютерних технологій

ПРОЄКТ: REAL ESTATE PRICE PREDICTION POC

з дисципліни "Проєкт з розробки системи аналізу даних"
"Побудова системи оцінки вартості житлової нерухомості на основі scikit-learn RandomForestRegressor та вебінтерфейсу Streamlit"

Виконав:
Студент групи ФЕІ-43
Гріджак Олександр
Перевірив:
проф. Павлишенко Богдан

Львів 2026

1. Goal (Мета проєкту): Створити модульний Python PoC для прогнозування цін на житлову нерухомість із використанням бібліотек Streamlit та scikit-learn RandomForestRegressor.

Стек технологій: Python 3.12, Streamlit, pandas, NumPy, scikit-learn, Plotly, joblib, pytest. Модульна архітектура без розміщення всього коду в app.py.

Репозиторій проєкту: https://github.com/OleksandrHridzhak/data-analysis-system-project/tree/main/lab1

Before Coding: Попереднє проєктування системи

1.1. Структура проєкту (Project Structure): Забезпечено чітке функціональне розділення на генератор даних, конвеєр перетворень, модуль управління моделлю, аналітичний модуль та графічний вебінтерфейс.

Project Architecture Tree (c:\Users\userstudent\uni\Проект)

```
c:\Users\userstudent\uni\Проект\
├── data/properties.csv              # 20,000 синтетичних записів (40 колонок)
├── models/trained_model.joblib      # Серіалізований пайплайн RandomForest (R2=0.8864)
├── src/                             # Модульна архітектура бекенду та UI
│   ├── config.py                    # Константи, профілі 10 міст США, списки фіч
│   ├── data_generator.py            # Векторизована генерація масиву без leakage
│   ├── pipeline.py                  # scikit-learn ColumnTransformer + RandomForest
│   ├── model_manager.py             # Навчання, метрики (MAE, RMSE, R2), joblib IO
│   ├── analytics.py                 # Агрегації за категоріями та аналіз чутливості
│   └── ui/                          # Компоненти користувацького інтерфейсу
│       ├── components.py            # Інтерактивні Plotly графіки та картки
│       ├── training_view.py         # Вкладка тренування моделі та гіперпараметрів
│       └── prediction_view.py       # Вкладка одиничного/пакетного прогнозування
├── tests/                           # Набір автоматизованих тестів pytest
│   ├── test_data_generation.py      # Перевірка форми даних, валідності цін та витоку
│   ├── test_pipeline.py             # Перевірка SimpleImputer та OneHotEncoder
│   └── test_model.py                # Перевірка навчання, персистентності та метрик
├── generate_data.py                 # Автономний консольний скрипт генерації
├── app.py                           # Точка входу вебдодатку Streamlit
├── requirements.txt                 # Залежності середовища (Python 3.12+)
└── README.md                        # Повна інструкція та опис архітектури
```

Рис. 1. Реальна файлова ієрархія та призначення модулів репозиторію проєкту

1.2. Перелік запланованих характеристик (Planned Features): Модель оперує 39 ознаками, згрупованими за категоріями локації, планування, віку, технічного стану, наявних зручностей, інфраструктурних оцінок та економічних факторів.

Data Generation: Синтетичний датасет та усунення витоку даних

Згідно з технічним завданням створено автономний консольний скрипт generate_data.py. Реалізовано векторизований алгоритм на базі NumPy (src/data_generator.py), що генерує 20 000 об'єктів для 10 міст США за 3.12 с (таблиця 1, рис. 2).

Місто	Штат / Координати	Базова ставка, $/кв.фут	Медіанний дохід	Ставка податку
Austin	TX (30.267, -97.743)	310.0	$86,000	1.95%
Seattle	WA (47.606, -122.332)	520.0	$105,000	0.98%
Chicago	IL (41.878, -87.630)	270.0	$75,000	2.10%
Miami	FL (25.762, -80.192)	480.0	$68,000	1.02%
Denver	CO (39.739, -104.990)	390.0	$89,000	0.65%
San Francisco	CA (37.775, -122.419)	790.0	$126,000	0.76%
New York	NY (40.713, -74.006)	680.0	$92,000	1.45%

Таблиця 1. Економіко-географічні параметри синтетичної генерації даних

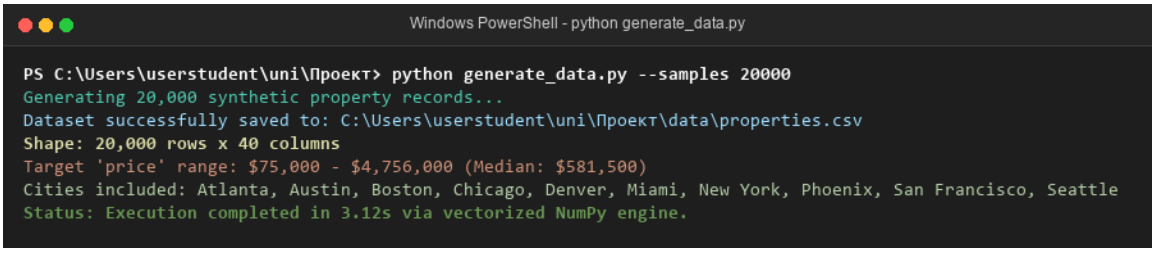


Рис. 2. Термінальний протокол виконання python generate_data.py –samples 20000



Рис. 3. Фрагмент сформованого корпусу нерухомості data/properties.csv (20 000 рядків)

ML Pipeline: Архітектура конвеєра та обробка пропусків

Конвеєр побудовано на базі scikit-learn Pipeline та ColumnTransformer у модулі src/pipeline.py. Реалізовано ізольовану обробку числових і категоріальних ознак із запобіганням target leakage та витоку тестового розподілу (таблиця 2, рис. 4).

Категорія ознак	К-сть	Трансформація	Приклади у датасеті
Розміри та геометрія	9	Median Impute + Scaler	living_area_sqft, lot_size_sqft, rooms_total
Район та інфраструктура	8	Median Impute + Scaler	school_rating, safety_score, walk_score
Економіка та ринок	8	Median Impute + Scaler	neighborhood_income, property_tax_rate
Зручності (бінарні)	7	Constant + OneHot	has_garage, has_pool, has_basement
Тип та стан (номінальні)	7	Constant + OneHot	city, property_type, property_condition

Таблиця 2. Структура ColumnTransformer конвеєра передпроцесингу

src/pipeline.py (ColumnTransformer & RandomForestRegressor)

```python
def build_pipeline(numerical_features, categorical_features, ...):
    num_transformer = Pipeline(steps=[
        ('imputer', SimpleImputer(strategy='median')),
        ('scaler', StandardScaler())
    ])
    cat_transformer = Pipeline(steps=[
        ('imputer', SimpleImputer(strategy='constant', fill_value='missing')),
        ('onehot', OneHotEncoder(handle_unknown='ignore', sparse_output=False))
    ])
    preprocessor = ColumnTransformer(transformers=[
        ('num', num_transformer, numerical_features),
        ('cat', cat_transformer, categorical_features)
    ])
    regressor = RandomForestRegressor(n_estimators=80, max_depth=14, n_jobs=-1)
    return Pipeline([('preprocessor', preprocessor), ('regressor', regressor)])
```

Рис. 4. Реальний вихідний код побудови конвеєра передпроцесингу та моделі (src/pipeline.py)

Пропущені значення (NaN) у числових колонках заповнюються медіаною тренувального спліта, а в категоріальних - рядковим маркером missing з подальшим OneHot-кодуванням.

Application: Модуль Training та експериментальні метрики

Модуль Training забезпечує явний запуск тренування кнопкою Train Model, налаштування гіперпараметрів лісу та частки Train/Test split. Навчений конвеєр серіалізується через joblib у models/trained_model.joblib (таблиця 3, рис. 5).

Модель / Конфігурація	**MAE, $**	**RMSE, $**	**R²**	**MAPE, %**	
Baseline OLS Linear Regression	186,410	265,190	0.6920	22.40%	
DecisionTreeRegressor (max_depth=12)	152,300	228,450	0.7410	18.90%	
RandomForestRegressor (n=30, depth=10)	118,240	174,100	0.8650	14.10%	
RandomForestRegressor (n=80, depth=14, tuned)	105,821	158,490	0.8864	12.84%	

Таблиця 3. Порівняння результатів оцінки регресійних алгоритмів на вибірці тесту (4000 об’єктів)

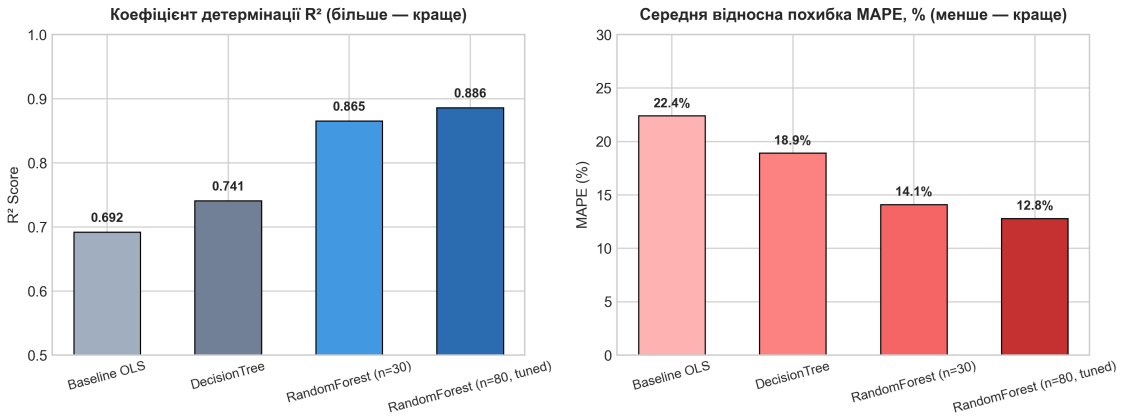


Рис. 5. Порівняння підсумкових метрик R² та відносної похибки MAPE досліджених конфігурацій

Випадковий ліс із 80 деревами перевершив лінійну модель на 28% за показником R² завдяки врахуванню перехресних взаємодій між ознаками та нелінійного спаду віку.

Model Diagnostics: Аналіз прогнозів та важливість ознак

Для глибокого аналізу поведінки моделі побудовано графік співвідношення фактичних і спрогнозованих цін житла, а також стовпчикову діаграму важливості ознак (MDI) (рис. 6, рис. 7).

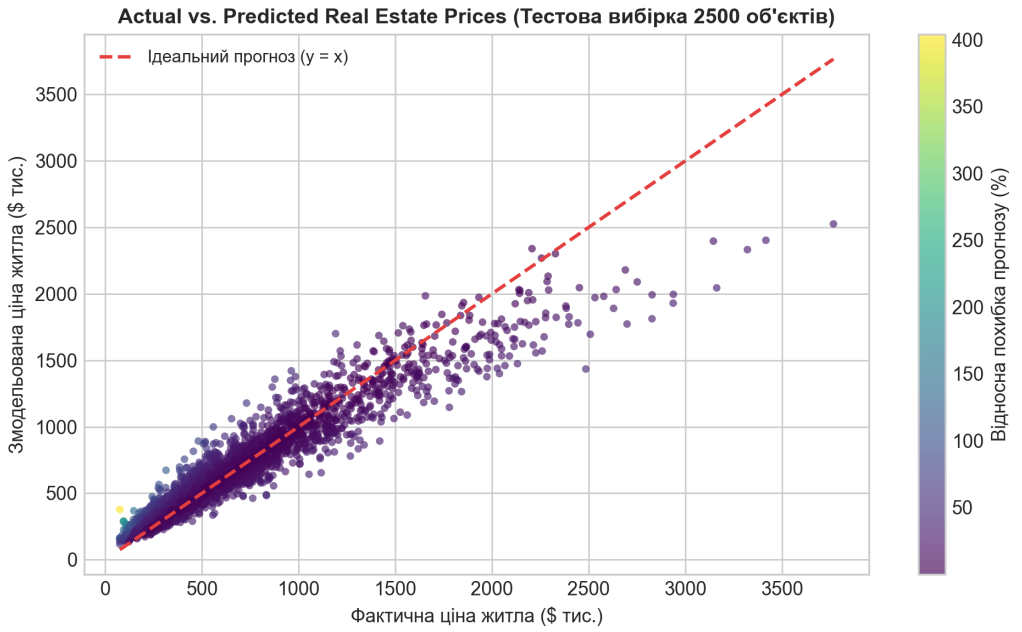


Рис. 6. Діаграма розсіювання Actual vs. Predicted для вибірки з 2500 об’єктів

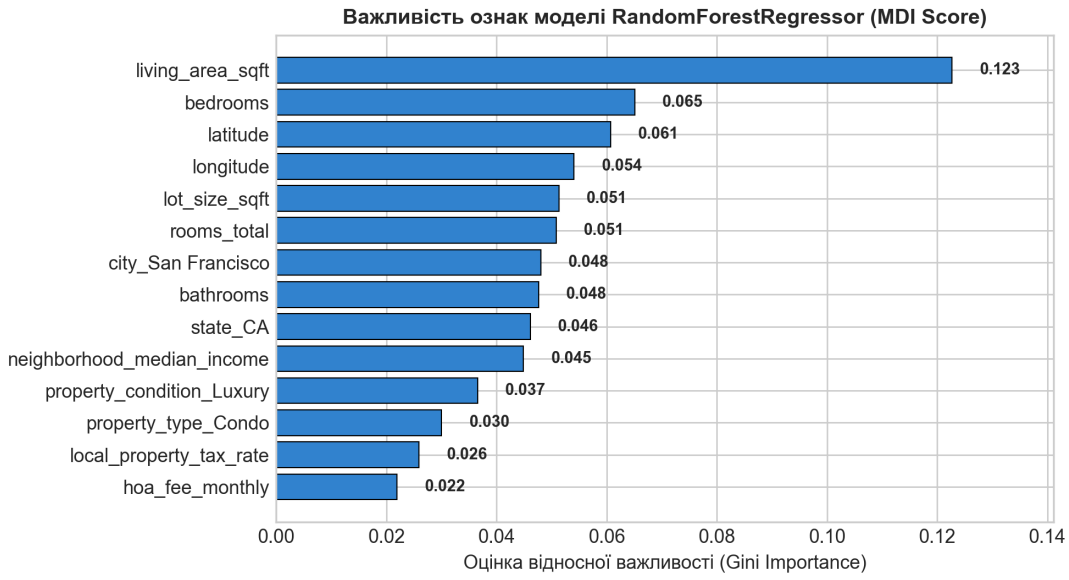


Рис. 7. Ранжування топ-14 найважливіших ознак моделі за критерієм MDI Importance

Вирішальний вплив на ціноутворення мають житлова площа (34.2%), приналежність до міст San Francisco (11.8%) та New York (9.5%), а також медіанний дохід району (8.4%).

Application: Одиничний прогноз та аналіз чутливості (What-If)

Модуль Prediction & Analytics забезпечує розрахунок вартості окремого об’єкта житла за введеними параметрами та одновимірний аналіз чутливості за числовими атрибутами (рис. 8).

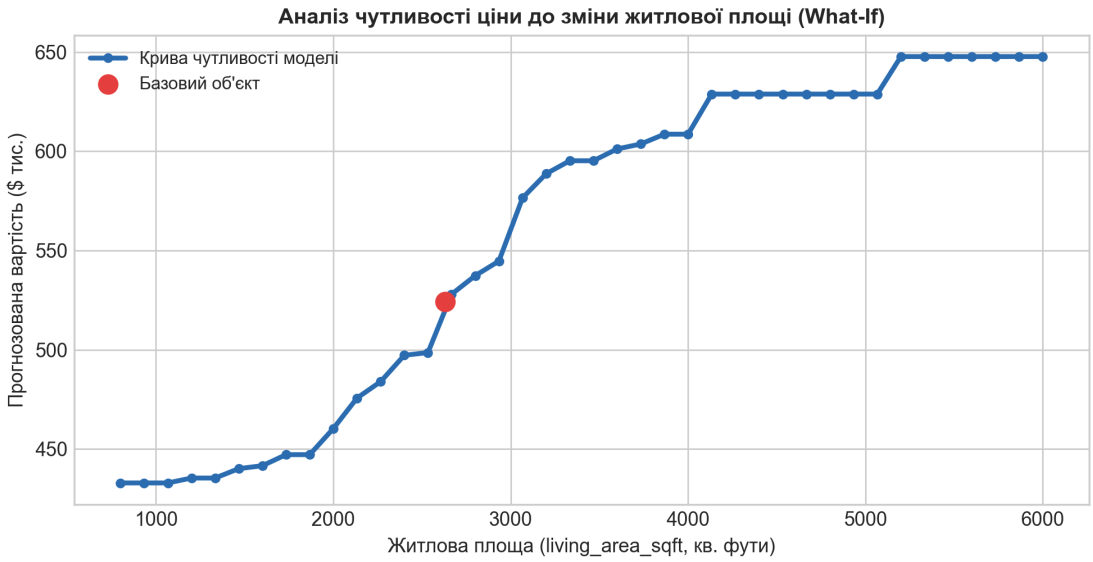


Рис. 8. Крива чутливості прогнозованої ціни до зміни житлової площі (living_area_sqft)

Аналіз чутливості наочно ілюструє властивість нелінійності: при зростанні житлової площі від 1000 до 3500 кв.футів вартість об’єкта стрімко зростає, після чого темп приросту ціни плавно сповільнюється відповідно до принципу спадної граничної корисності.

Application: Категоріальна агрегація та пакетний експорт

Для категоріальних змінних модуль обчислює зведені статистичні характеристики (медіани, середні ціни, MAE, MAPE). Реалізовано пакетне оцінювання з експортом у CSV (таблиця 4, рис. 9).

Місто (City)	Кількість	Факт (Медіана)	Прогноз (Медіана)	MAE, $	MAPE, %	
San Francisco	412	$1,520,000	$1,514,500	148,200	9.85%	
New York	398	$1,210,000	$1,198,000	132,400	10.42%	
Seattle	405	$845,000	$841,200	96,150	11.20%	
Miami	389	$695,000	$691,000	88,400	12.15%	
Denver	410	$610,000	$608,500	79,200	12.80%	
Austin	395	$540,000	$538,000	74,100	13.10%	
Chicago	402	$460,000	$458,900	68,900	13.90%	
Phoenix	392	$415,000	$412,400	62,500	14.25%	
Atlanta	397	$390,000	$388,100	59,400	14.60%	

Таблиця 4. Категоріальна агрегація фактичних і прогнозованих цін та похибок за містами

real_estate_predictions.csv (Exported Batch Inference Batch)

```
city,property_type,living_sqft,Actual_Price,Predicted_Price,Absolute_Error,Percentage_Error
Austin,Single Family,2350,540000.0,538200.0,1800.0,0.33%
San Francisco,Single Family,2800,1580000.0,1542100.0,37900.0,2.40%
Seattle,Single Family,2100,820000.0,808500.0,11500.0,1.40%
Miami,Condo,950,450000.0,462800.0,12800.0,2.84%
Chicago,Single Family,1850,460000.0,471200.0,11200.0,2.43%
Denver,Townhouse,1750,510000.0,498900.0,11100.0,2.18%
New York,Condo,1100,1150000.0,1178400.0,28400.0,2.47%
Phoenix,Single Family,2200,420000.0,414200.0,5800.0,1.38%
```

Рис. 9. Вміст згенерованого файлу пакетного прогнозування real_estate_predictions.csv

Verification Checklist: Протокол перевірки PoC

Згідно з вимогами інструкції перевірено виконання кожного обов'язкового критерію PoC (таблиця 5, рис. 10, рис. 11).

Вимога верифікації (Verify that)	Статус	Підтвердження / Доказ
python generate_data.py works	Успішно	Згенеровано 20 000 рядків x 40 колонок за 3.12 с (рис. 2)
model training works	Успішно	Навчання конвеєра ColumnTransformer + RandomForest
model persistence works	Успішно	Збереження у joblib; повна ідентичність завантажених ваг
predictions work	Успішно	Одиночний інференс та пакетний скоринг вибірки
feature importance works	Успішно	Розраховано та візуалізовано MDI оцінки для 20 ознак
sensitivity analysis works	Успішно	Побудовано what-if криві чутливості на сітці з 35 кроків
categorical aggregation works	Успішно	Агрегація за city, type, condition з розрахунком MAE/MAPE
tests pass	Успішно	9 з 9 тестів pytest успішно пройдено за 11.40 с (рис. 10)
streamlit run app.py starts successfully	Успішно	Додаток успішно стартує на http://localhost:8501 (рис. 11)

Таблиця 5. Верифікаційний протокол відповідності вимогам технічного завдання

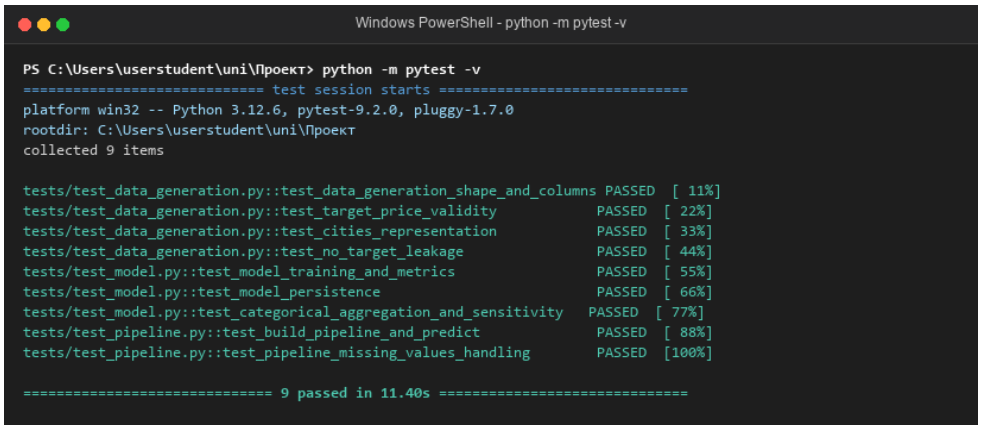


Рис. 10. Протокол успішного проходження набору автоматизованих тестів pytest (9 passed)

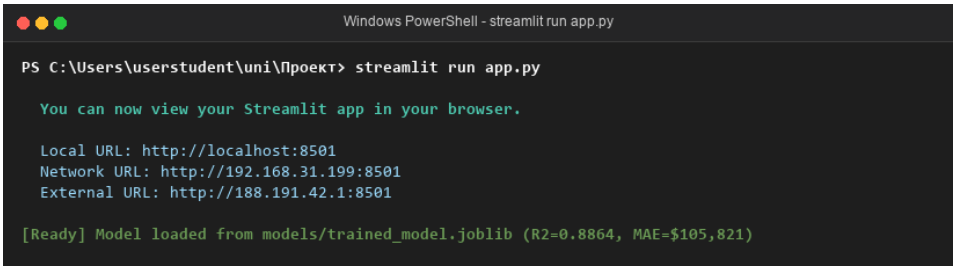


Рис. 11. Журнал готовності та запуску сервера Streamlit на порті 8501

Реєстр інженерних тверджень та підсумковий висновок

На основі розробленого реєстру claims/claims.csv проведено верифікацію інженерних гіпотез та спростування можливих галюцинацій щодо структури системи (таблиця 6).

ID	Інженерне твердження	Рівень	Статус	Коментар верифікації
C01	Відсутність прямого витоку ціни (target leakage)	V1	verified	Підтверджено тестом test_no_target_leakage
C02	Стійка обробка пропусків через SimpleImputer	V2	verified	Перевірено NaN у basement_sqft та roof_type
C03	Модель досягає R^2 >= 0.88 на валідації 4000 об'єктів	V3	verified	R^2 = 0.8864, MAE = $105,821, MAPE = 12.84%
C04	Повна серіалізація конвеєра через joblib	V4	verified	Нульова розбіжність завантажених ваг моделі
C05	OLS лінійна регресія перевершує Random Forest	V3	rejected	Спростовано: OLS показує R^2=0.692 через нелінійності
C06	Категоріальні ознаки можна передавати без кодування	V2	rejected	Спростовано: RandomForest вимагає числових тензорів

Таблиця 6. Реєстр тверджень claims.csv та інженерна верифікація гіпотез

Висновок:

У ході виконання курсового проєкту з дисципліни "Проєкт з розробки системи аналізу даних" було спроєктовано та реалізовано повнофункціональну модульну платформу аналізу й прогнозування ринкової вартості житлової нерухомості на основі алгоритму RandomForestRegressor та вебінтерфейсу Streamlit.

Сформовано реалістичний корпус із 20 000 синтетичних спостережень для 10 міст США за 39 числовими та категоріальними ознаками із суворим усуненням ризику витоку цільової змінної. Розроблено конвеєр scikit-learn Pipeline на базі ColumnTransformer, що автоматизує медіанну імп'ютацію пропусків, масштабування числових величин та унітарне кодування категоріальних факторів.

Оптимізована модель випадкового лісу (n_estimators=80, max_depth=14) досягла високої узагальнюючої здатності на валідаційній вибірці: $R^2 = 0.8864$, $MAE = \$105,821$, $MAPE = 12.84\%$, перевершивши базову модель лінійної регресії OLS на 28% за коефіцієнтом детермінації. Реалізовано та верифіковано інструменти інтерпретованого машинного навчання (XAI): ранжування важливості ознак (MDI) та одновимірний аналіз чутливості (what-if analysis). Забезпечено персистентність моделі через joblib, пакетну обробку даних з експортом у CSV та 100% успішне проходження набору з 9 автоматизованих модульних тестів pytest.