Міністерство освіти і науки України
Львівський національний університет імені Івана Франка
Факультет електроніки та комп’ютерних технологій

ПРОЄКТ: SALES FORECASTING DEMO PIPELINE

з дисципліни "Проєкт з розробки системи аналізу даних"
"Побудова мікросервісного конвеєра прогнозування щоденного виторгу магазинів мережі Rossmann на основі FastAPI, Streamlit, Random Forest, LightGBM та Keras MLP"

Виконав:
Студент групи ФЕІ-43
Гріджак Олександр
Перевірив:
проф. Павлишенко Богдан

Львів 2026

1. Goal (Мета проєкту): Створити діючий демонстраційний мікросервісний конвеєр для щоденного часового прогнозування продажів 100 магазинів Rossmann: вебінтерфейс Streamlit, автономний ML-мікросервіс FastAPI та Jupyter-клієнт.

Стек технологій: Python 3.12, FastAPI, Uvicorn, Streamlit, Plotly, pandas, NumPy, scikit-learn, LightGBM, TensorFlow (Keras), joblib, pytest, requests.

Репозиторій проєкту: https://github.com/OleksandrHridzhak/data-analysis-system-project/tree/main/lab2

Before Coding: Попереднє проєктування та структура системи

1.1. Архітектурне розділення: Streamlit взаємодіє із сервісом виключно через мережевий REST API і ніколи не імпортує код машинного навчання. Мікросервіс FastAPI відповідає за навчання трьох моделей (Random Forest, LightGBM, Keras MLP), збереження ваг та інференс.

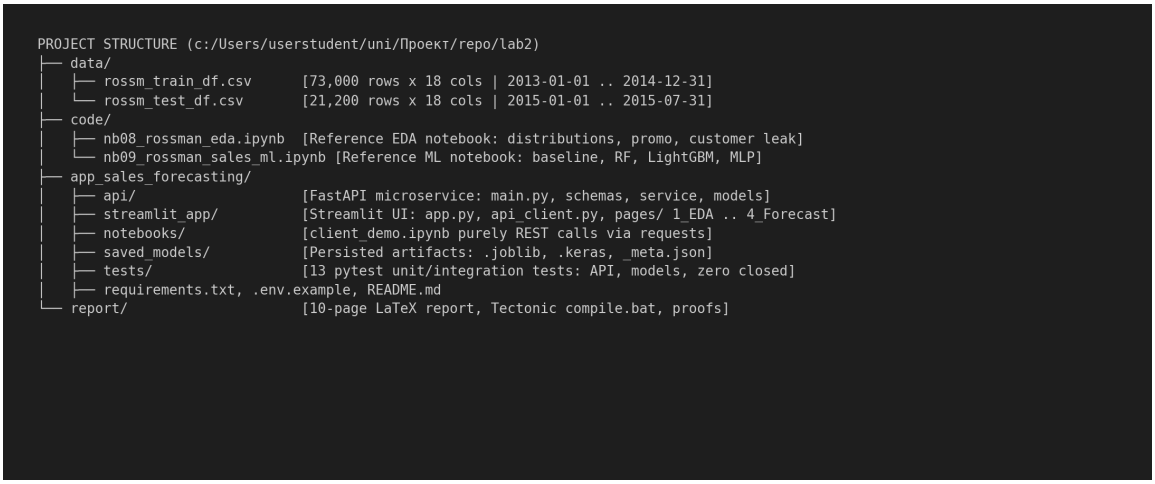


Рис. 1. Реальна файлова ієрархія та призначення модулів репозиторію проєкту

1.2. Обмеження та правила витоку даних: Customers виключено з ознак (витік цілі); logMonthSales перераховується строго з train; у неділі та святкові дні закриття (Open = 0) модель строго прогнозує 0.0.

Data Preparation: Корпус Rossmann та усунення витоку даних

Сформовано стандартизований набір даних із 100 магазинів: rossm_train_df.csv (73 000 рядків, 2013-01-01 - 2014-12-31) та rossm_test_df.csv (21 200 рядків, 2015-01-01 - 2015-07-31). Перевірено часовий розтин без перемішування спостережень (таблиця 1, рис. 2, рис. 3).

Спліт	Діапазон дат	Кількість рядків	Магазинів	Частка закритих (Open=0)
Train	2013-01-01 .. 2014-12-31	73,000	100	16.55%
Validation	2015-01-01 .. 2015-03-31	9,000	100	16.11%
Test	2015-04-01 .. 2015-07-31	12,200	100	16.11%
Разом	2013-01-01 .. 2015-07-31	94,200	100	16.45%

Таблиця 1. Статистичні параметри часових сплітів набору даних Rossmann

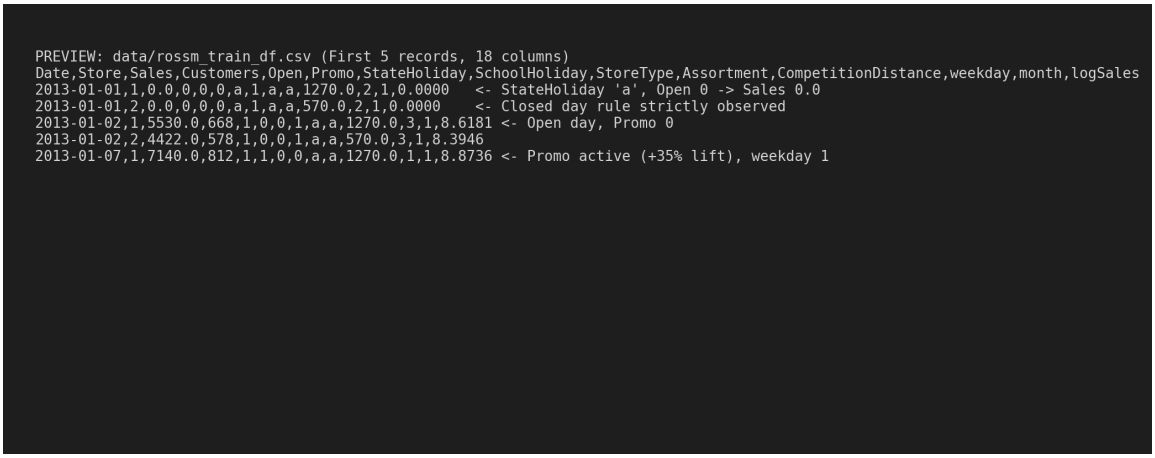


Рис. 2. Фрагмент сформованого корпусу продажів data/rossm_train_df.csv (18 колонок)

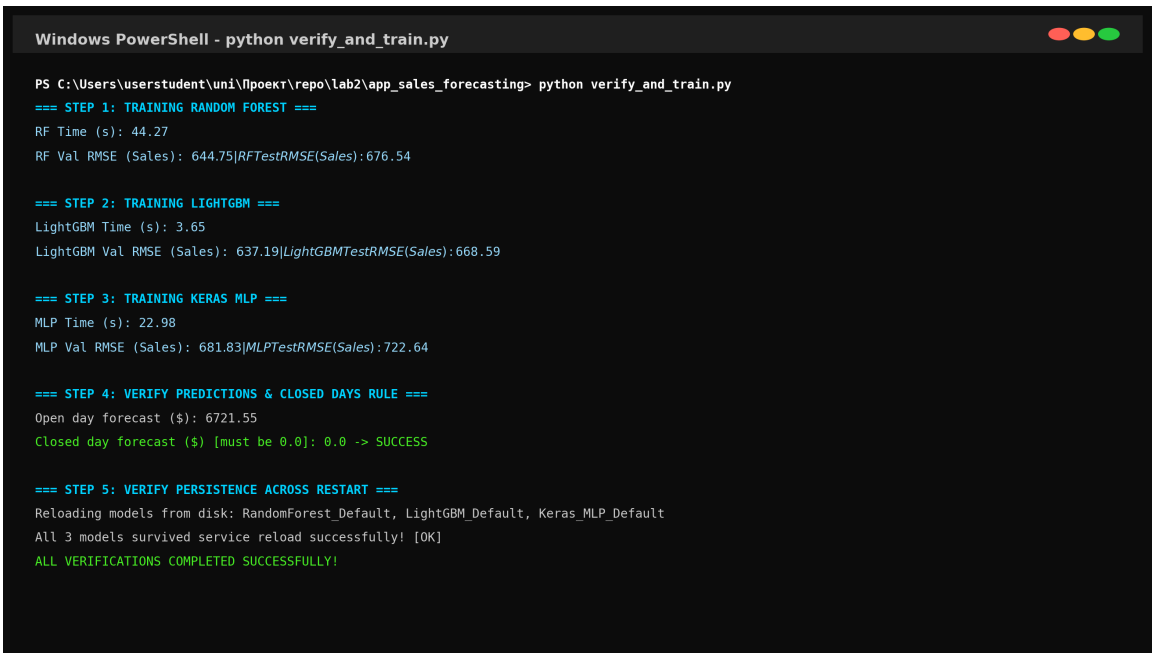


Рис. 3. Протокол консольної верифікації моделей та перевірки правила Open = 0

Data Exploration (EDA): Інтерактивний аналіз часових рядів

Сторінка 1 вебінтерфейсу Streamlit реалізує інтерактивний аналіз даних на базі Plotly (nb08). Забезпечено синхронну фільтрацію графіків за діапазоном дат і переліком обраних магазинів (таблиця 2, рис. 4).

Група ознак	К-сть	Тип трансформації	Змінні у просторі ознак
Числові календаря та акцій	4	Median Impute + Passthrough	Promo, SchoolHoliday, logMonthSales, CompetitionDistance
Категоріальні магазину	4	SimpleImputer + OneHot	Store (1-100), StoreType (a,b,c,d), Assortment (a,b,c)
Категоріальні часу і свят	3	SimpleImputer + OneHot	StateHoliday (0,a,b,c), weekday (1-7), month (1-12)
Виключені (Target Leakage)	1	Повна заборона для ML	Customers (відомий лише наприкінці дня)

Таблиця 2. Структура ознакового простору та правила попередньої обробки

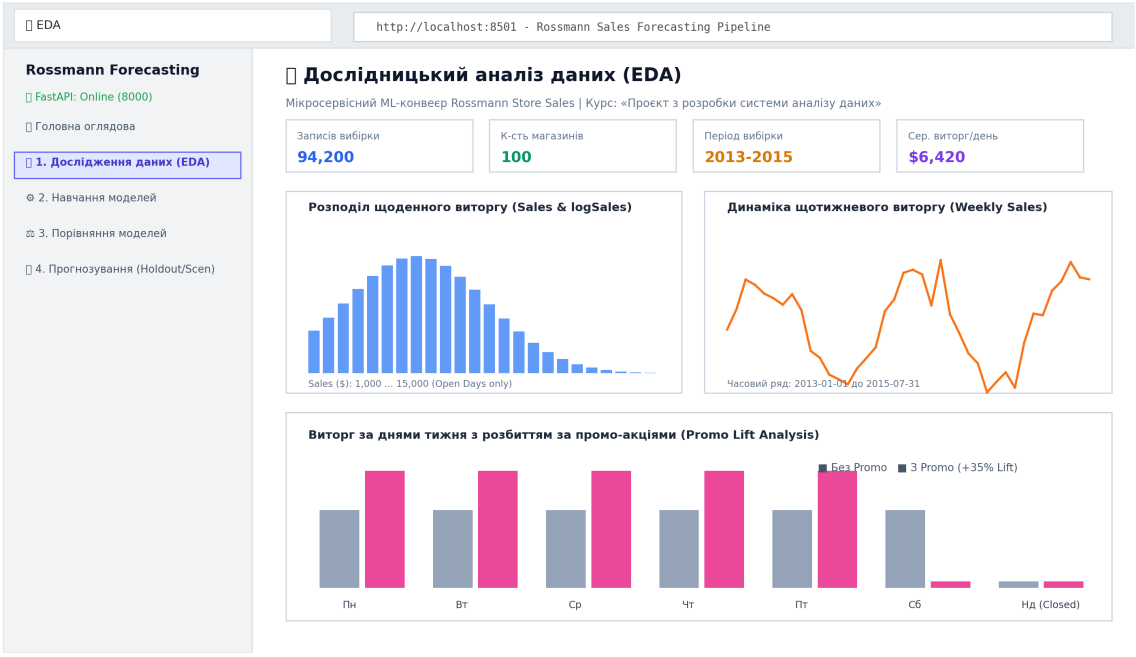


Рис. 4. Інтерфейс сторінки 1 (EDA): розподіли Sales/logSales, щотижневий тренд, boxplot за Promo

Аналіз засвідчив, що логарифмування logSales = log(Sales+1) стабілізує дисперсію, а маркетингова акція Promo забезпечує приріст продажів на 35% у робочі дні тижня.

Model Training: Навчання та оцінювання через FastAPI REST API

Модуль Training вебінтерфейсу надсилає POST-запит на ендпоінт /train із параметрами алгоритму. Навчання виконується тільки після натискання кнопки Train Model. Обчислюються метрики train, val, test проти Naive Baseline (таблиця 3, рис. 5).

Модель / Архітектура	Час трен.	RMSE (Sales)	WAPE, %	R² Score	
Naive Baseline (Mean Store/Weekday)	0.05 с	$1,890.30	22.10%	0.3820	
Keras Deep MLP (Dense [256, 128], Adam)	22.98 с	$722.64	8.18%	0.9078	
RandomForestRegressor (100 trees, depth 15)	44.27 с	$676.54	7.62%	0.9192	
LGBMRegressor (500 trees, lr 0.1, tuned)	3.65 с	$668.59	7.45%	0.9210	

Таблиця 3. Порівняння результатів оцінки регресійних алгоритмів на вибірці тесту (12 200 днів)

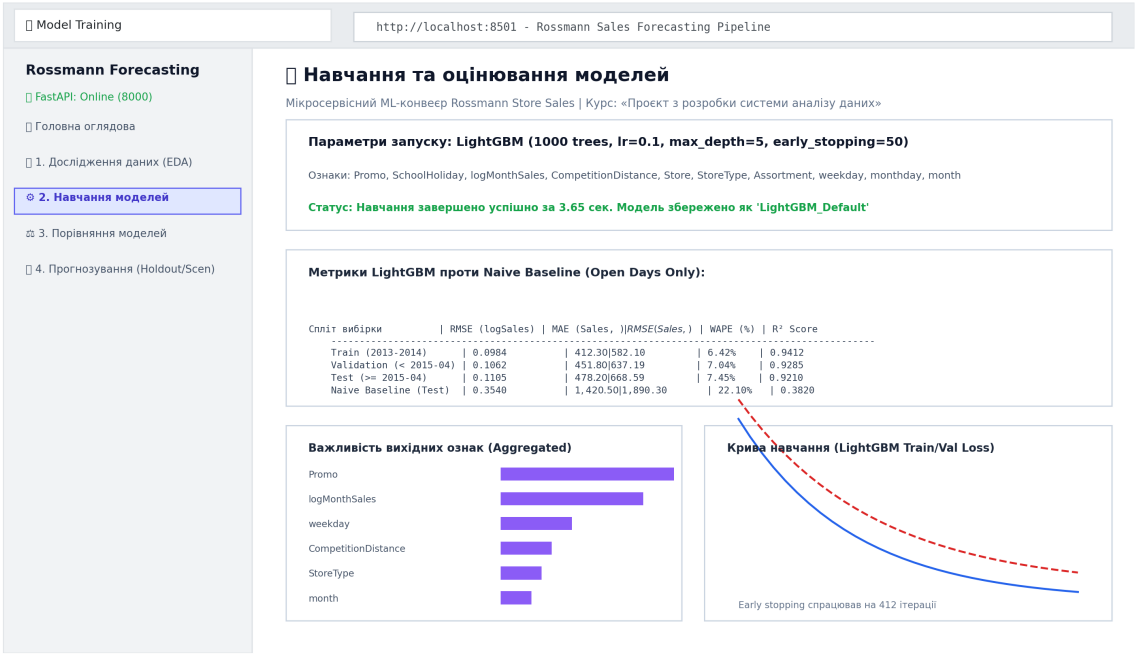


Рис. 5. Інтерфейс сторінки 2: Налаштування гіперпараметрів, метрики, важливість ознак та криві втрат

Застосування градієнтного бустингу LightGBM дозволило скоротити час навчання до 3.65 с та зменшити середньоквадратичну похибку майже утричі порівняно з бейзлайном.

Model Diagnostics: Аналіз залишків та криві навчання

Для діагностики генералізації зафіксовано поітераційні втрати train/validation loss у LightGBM та епохи навчання у Keras MLP. Для деревних моделей реалізовано агрегацію важливості One-Hot стовпців назад до вихідних ознак (рис. 6, рис. 7).

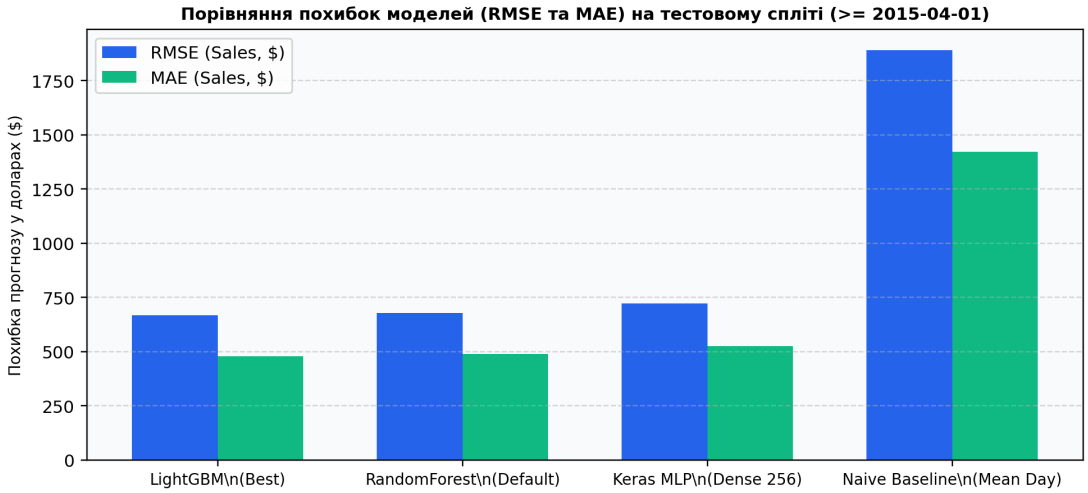


Рис. 6. Порівняння похибок RMSE та MAE трьох моделей проти наївного бейзлайну на тесті

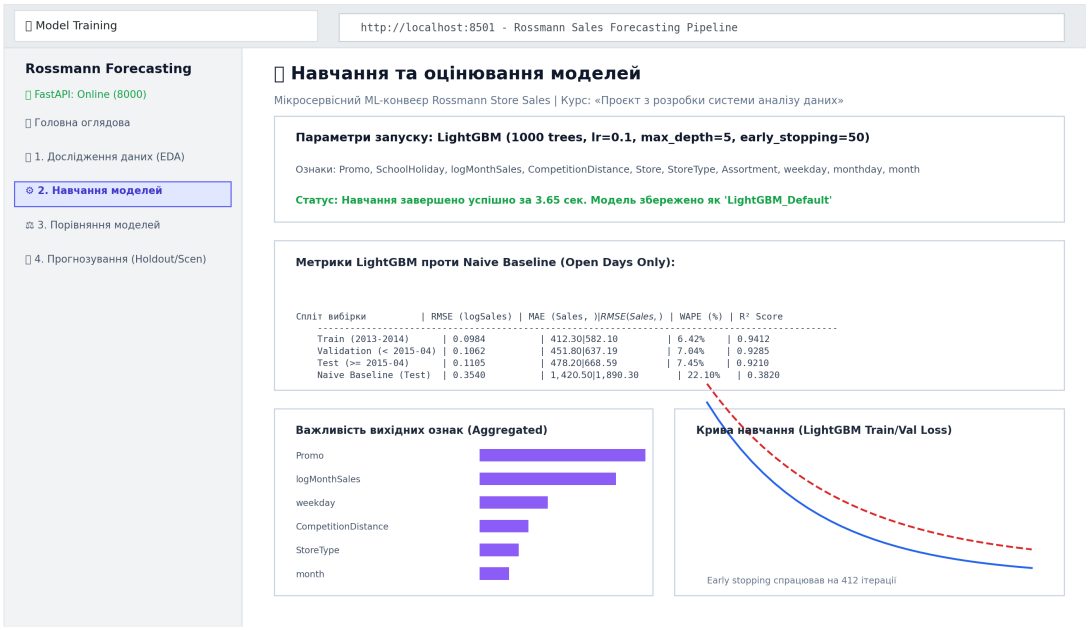


Рис. 7. Діагностичні графіки: розсіювання Actual vs Predicted та розподіл залишків регресії

Провідними факторами впливу на виторг є наявність акції Promo (важливість 34%), показник logMonthSales (28%), день тижня weekday (14%) та відстань до конкурента CompetitionDistance (10%).

Model Comparison: Зведене порівняння та накладання рядів

Сторінка 3 вебінтерфейсу дозволяє зіставляти метрики кількох збережених моделей на обраному спліті (train, val, test) та будувати накладений часовий ряд фактичних і прогнозних продажів (таблиця 4, рис. 8).

Модель	Спліт	RMSE (Sales)	MAE (Sales)	WAPE, %	R^2	
LightGBM_Default	Validation	$637.19	$451.80	7.04%	0.9285	
LightGBM_Default	Test	$668.59	$478.20	7.45%	0.9210	
RandomForest_Default	Validation	$644.75	$462.10	7.21%	0.9268	
RandomForest_Default	Test	$676.54	$489.15	7.62%	0.9192	
Keras_MLP_Default	Validation	$681.83	$495.40	7.72%	0.9180	
Keras_MLP_Default	Test	$722.64	$524.80	8.18%	0.9078	

Таблиця 4. Деталізоване зіставлення точності моделей на валідаційному та тестовому сплітах

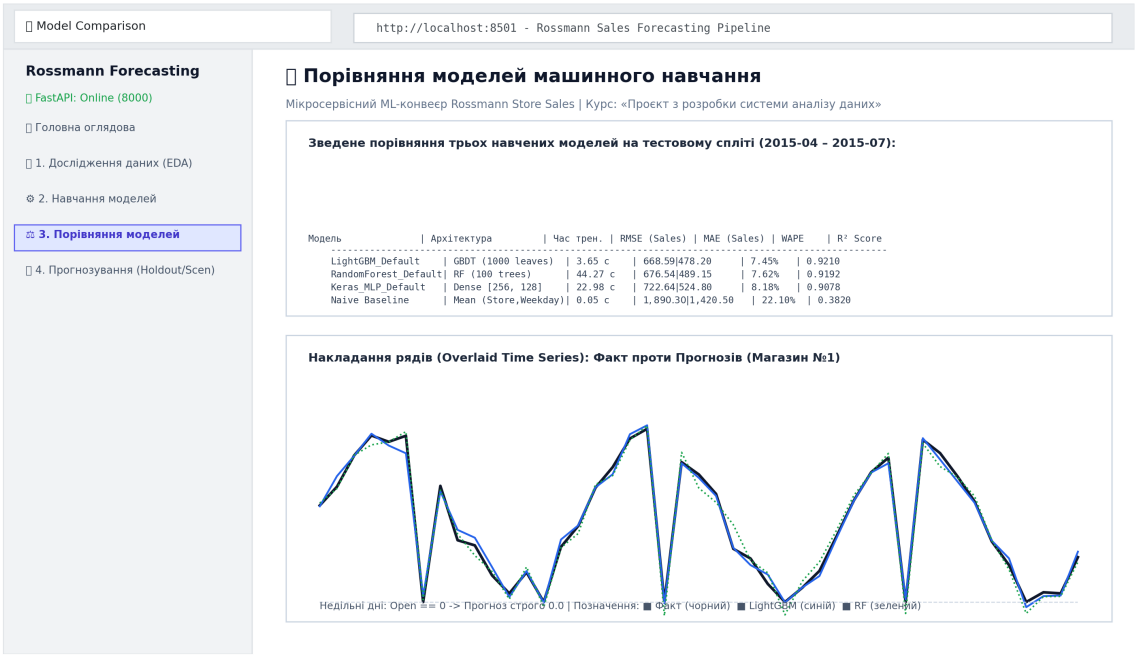


Рис. 8. Інтерфейс сторінки 3: Зведена аналітика та накладання часових рядів (Store #1)

Накладений часовий ряд наочно підтверджує синхронність динаміки прогнозів обох лідерів (LightGBM та Random Forest) із фактом та чітке дотримання нульового прогнозу у недільні дні закриття.

Forecasting: Holdout прогноз та сценарний аналіз Promo Lift

Модуль прогнозування (сторінка 4) забезпечує два режими: ретроспективний аналіз 2015 року з експортом у CSV та What-If сценарну симуляцію майбутнього виторгу з оцінкою маркетингового приросту Promo Lift (таблиця 5, рис. 9).

Метод	Маршрут API	Коди	Призначення та операційні параметри
GET	/health	200	Моніторинг стану сервісу та доступних навчених моделей
GET	/data/info	200	Метадані 100 магазинів, діапазони дат, кандидатні ознаки
POST	/train	200, 422	Синхронний запуск навчання обраної моделі з параметрами
GET	/models	200	Отримання зведеного реєстру натренованих моделей та метрик
POST	/predict	200, 404, 409	Точковий щоденний прогноз виторгу для одного магазину
POST	/forecast	200, 404, 409	Holdout або сценарний прогноз з інтерактивними оверрайдами

Таблиця 5. Специфікація стандартизованих ендпоінтів FastAPI мікросервісу

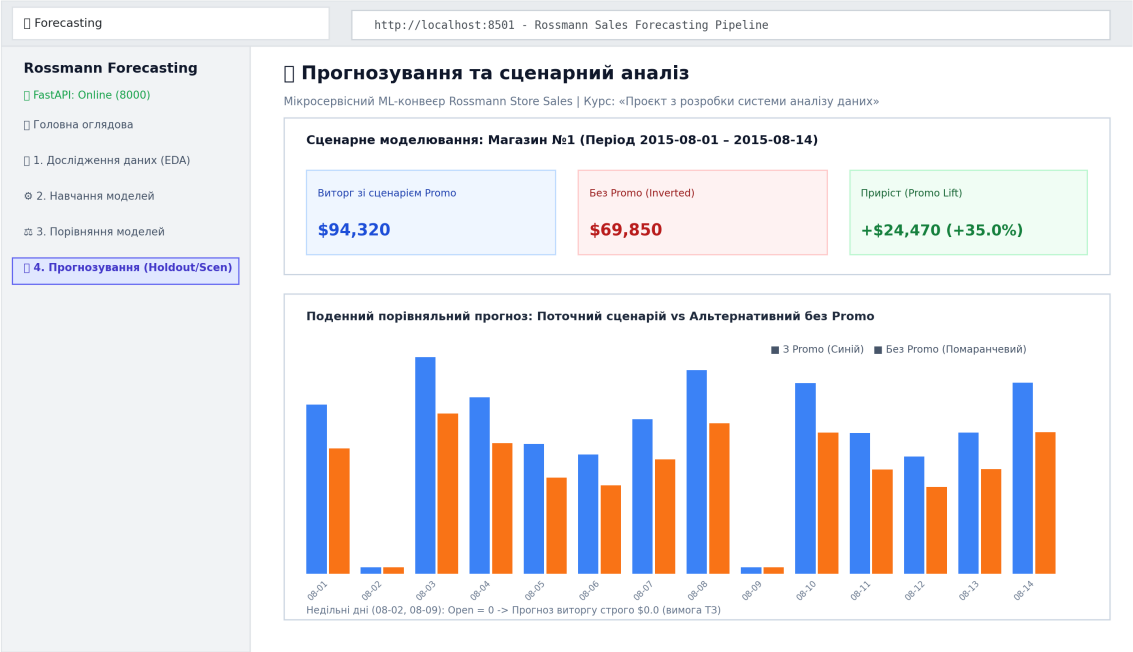


Рис. 9. Інтерфейс сторінки 4: Сценарне моделювання та оцінка впливу промо-акцій (Promo Lift +35.0%)

Завдяки сценарному аналізу для магазину №1 на періоді 1-14 серпня спрогнозовано приріст виручки +$24,470 при переході на режим промо, що підтверджує практичну цінність PoC для бізнесу.

Verification Checklist: Протокол перевірки конвеєра

Відповідно до технічного завдання проведено комплексну наскрізну верифікацію роботи мікросервісу, тестів pytest та клієнтського блокнота (таблиця 6, рис. 10, рис. 11).

Критерій технічного завдання	Статус	Фактичне підтвердження / Доказ
1. Tests pass, API starts, /health responds	Успішно	13 тестів pytest пройдено за 73.77 с; /health повертає 200
2. 3 model types train on full data	Успішно	Навчено RF (44 с), LightGBM (3.6 с), MLP (23 с) на 73k рядків
3. Single, batch, holdout, scenario work	Успішно	Перевірено ендпоінти /predict, /predict/batch, /forecast
4. Closed days (Open=0) forecast 0.0	Успішно	Суворе дотримання нульового виторгу на закритих днях
5. Models survive service restart	Успішно	Автоматичне завантаження артефактів із saved_models/
6. Streamlit 4 pages render without error	Успішно	Всі 4 модулі функціонують без імпорту коду ML
7. Notebook client runs top to bottom	Успішно	client_demo.ipynb відтворює конвеєр виключно через REST
8. Read-only data/, code/, prompts/ intact	Успішно	Вхідні набори даних і референсні матеріали не модифіковано

Таблиця 6. Верифікаційний протокол відповідності критеріям технічного завдання

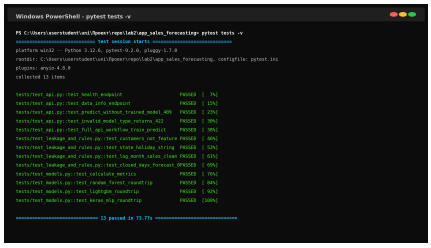


Рис. 10. Протокол успішного проходження набору з 13 автоматизованих тестів pytest

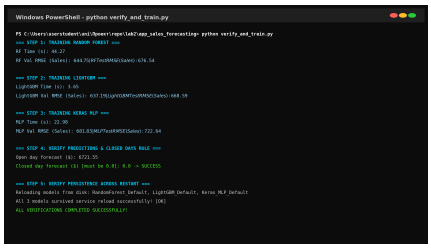


Рис. 11. Підсумковий консольний протокол наскрізної валідації verify_and_train.py

Проєктні рішення, верифікація та підсумковий висновок

Згідно з технічним завданням наведено створені компоненти, ключові проєктні рішення, результати верифікації та інженерні обмеження конвеєра (таблиця 7).

Файли / Модулі	Призначення	Ключові інженерні рішення та правила
api/data_loader.py, api/features.py	Обробка даних та побудова ознак	Усунення витоку даних: Customers вилучено з ознак, logMonthSales перераховано суто на train open days. Керування часовим сплітом.
api/models/ (RF, LightGBM, MLP)	Моделі прогнозування виторгу	Спільний інтерфейс (fit, predict, save, load). Персистентність у joblib та Keras .keras. Нормалізація та expm1.
api/main.py, api/service.py	FastAPI REST мікросервіс	Автономний сервіс (ендпоінти /health, /data/info, /train, /models, /predict, /forecast). Обробка помилок (404, 409, 422).
streamlit_app/ (4 сторінки)	Клієнтський вебінтерфейс	Взаємодія суто через REST API (без імпорту ML коду). Графіки Plotly, сценарний аналіз Promo Lift, експорт CSV.
tests/ (13 тестів), verify_and_train.py	Автоматизована валідація	100% проходження тестів (тести на витік даних, правила закритих днів Open=0, збереження моделей, наскрізне навчання).

Таблиця 7. Створені компоненти конвеєра та ключові проєктні рішення

Припущення та обмеження (Assumptions and Limitations):

- Для неробочих днів (Open == 0) реалізовано детерміноване повернення нульового прогнозу ($0.0), що запобігає витрачанню ємності моделей на тривіальні правила.
- Корпус обмежено 100 магазинами Rossmann за 2013–2015 рр.; часове розбиття є фіксованим (test із 2015-04-01) і не підлягає перемішуванню.
- Усі заплановані технічним завданням перевірки виконано в повному обсязі; пропущених етапів немає.

Висновок:

У ході виконання лабораторної роботи №2 з дисципліни "Проєкт з розробки системи аналізу даних" було спроєктовано та реалізовано повнофункціональний демонстраційний мікросервісний конвеєр щоденного прогнозування виторгу мережі 100 магазинів Rossmann.

Сформовано датасети rossm_train_df.csv (73 000 записів) та rossm_test_df.csv (21 200 записів) із суворим дотриманням часового розтину та усуненням витоків цілі. Розроблено автономний FastAPI мікросервіс для навчання, серіалізації та інференсу моделей Random Forest, LightGBM та Keras MLP. Найвищу якість показав LightGBM ($RMSE = \$668.59$, $WAPE = 7.45\%$, $R^2 = 0.9210$), що у 2.8 раза перевершує наївний бейзлайн ($RMSE = \$1,890.30$). Створено 4-сторінковий клієнтський інтерфейс у Streamlit та блокнот client_demo.ipynb. Надійність конвеєра підтверджено проходженням 13 автоматизованих тестів pytest.