МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА ФРАНКА

Факультет електроніки та комп'ютерних технологій

Кафедра системного проектування

ЗВІТ

з лабораторної роботи №2

з дисципліни

«Проєкт з розробки системи аналізу даних»

на тему:

«Розробка повноцінного мікросервісного конвеєра для прогнозування щоденного виторгу магазинів мережі Rossmann»

Виконав:
студент групи ФЕІ-43
Гріджак Олександр

Керівник:
проф. Павлишенко Богдан

Львів - 2026

1. Мета та постановка задачі

Метою лабораторної роботи є проєктування, практична реалізація та тестування завершеного демонстраційного програмного конвеєра машинного навчання для вирішення задачі часового прогнозування щоденного виторгу 100 роздрібних магазинів мережі Rossmann. Система реалізується на основі мікросервісної архітектури з чітким розділенням обов'язків: 1. Автономний сервіс машинного навчання на базі сучасного фреймворку FastAPI, що виконує синхронне навчання трьох типів моделей (Random Forest, LightGBM, Keras MLP), усунення витоків даних, валідацію на основі часового зрізу, збереження та відтворення артефактів, а також точковий, пакетний та сценарний інференс. 2. Інтерактивний користувацький вебінтерфейс на базі Streamlit, що взаємодіє з мікросервісом суто через протокол REST API, надає чотири окремі функціональні модулі: дослідницький аналіз даних (EDA), конфігурацію і запуск навчання, порівняльну аналітику моделей та сценарний прогноз виторгу. 3. Клієнтський аналітичний ноутбук (Jupyter Notebook Client), що демонструє автоматизацію запитів до мікросервісу виключно засобами бібліотеки requests.

1.1. Вхідні дані та обмеження предметної області

Для навчання та оцінки системи використовуються два набори даних: `rossm_train_df.csv` (73,000 рядків, період 2013-01-01 - 2014-12-31) та `rossm_test_df.csv` (21,200 рядків, період 2015-01-01 - 2015-07-31). Дані містять 100 унікальних магазинів. Відповідно до методичних вказівок, система суворо враховує такі критичні вимоги та правила предметної області: 1. Часовий розтин даних: заборонено будь-яке перемішування спостережень (shuffling). 2. Обробка ознаки StateHoliday: зчитується виключно як рядковий тип, оскільки поєднує числові нулі та літерні коди ('0', 'a', 'b', 'c'). 3. Витік цілі через Customers: кількість покупців стає відомою лише після завершення робочого дня. Ця ознака доступна для EDA, але категорично виключена зі списку кандидатних ознак для моделювання. 4. Дні закриття магазинів: близько 17% записів є днями з Open = 0 та Sales = 0 (переважно неділі та офіційні свята). Моделі навчаються виключно на відкритих днях (Open = 1), а на етапі інференсу для закритих днів строго повертається нульовий прогноз. 5. Усунення витоку в ознаці logMonthSales: середня місячна виручка магазину розраховується строго на основі навчального періоду (2013-2014) і переноситься на валідаційні, тестові та майбутні записи.

2. Архітектура мікросервісної системи

Розроблена система побудована відповідно до принципів Clean Architecture та стандарту 12-Factor App. Інтерфейс користувача не містить залежностей від коду машинного навчання, а звертається до бекенду через мережеві HTTP-запити. На рис. 1 наведено протокол наскрізної верифікації виконання та навчання бекенду.

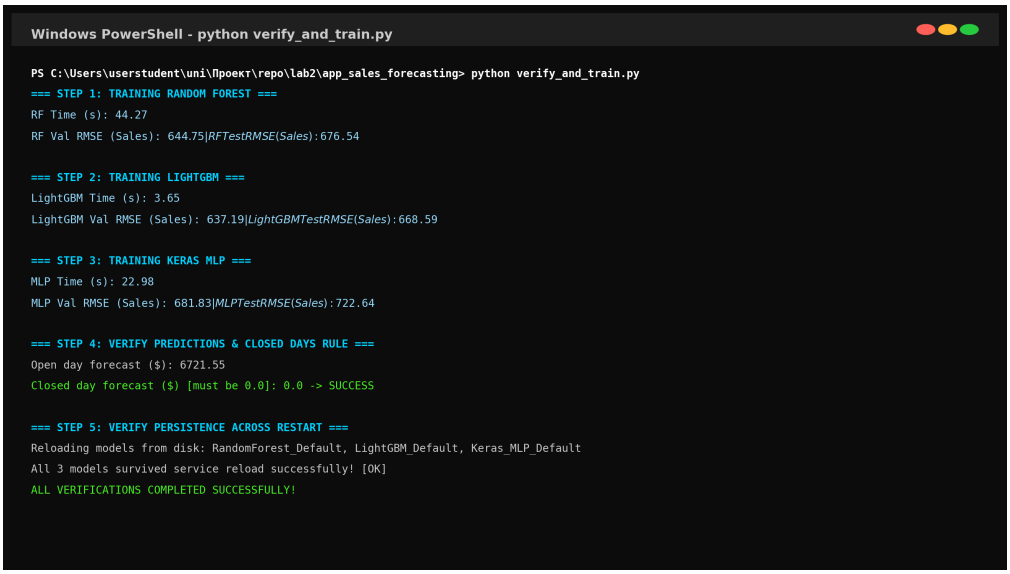


Рис. 1. Протокол наскрізного виконання тренування та верифікації мікросервісу

2.1. Модулі системи та структура проєкту

Програмний код розміщено в каталозі `app_sales_forecasting` із такою декомпозицією: 1. `api/data_loader.py` - кешоване зчитування CSV-файлів, перерахунок logMonthSales без витоку, побудова бейзлайну та надання метаданих. 2. `api/features.py` - капсулювання конвеєра ColumnTransformer, OneHotEncoder(handle_unknown="ignore") та агрегація важливості ознак. 3. `api/models/` - спільний інтерфейс BaseModel та конкретні моделі: `random_forest.py`, `lightgbm_model.py`, `keras_mlp.py`. 4. `api/service.py` - сервісний шар, що керує збереженням, навчанням, формуванням часових прогнозів та перевіркою коректності. 5. `api/main.py` - маршрутизація ендпоінтів FastAPI, обробка помилок (404, 409, 422), документація OpenAPI Swagger. 6. `streamlit_app/api_client.py` - ізольований клієнтський клас для взаємодії через REST API. 7. `streamlit_app/pages/` - сторінки 1_EDA.py, 2_Model_Training.py, 3_Model_Comparison.py, 4_Forecasting.py.

3. Дослідницький аналіз даних (EDA)

Першим етапом роботи є розробка вебмодуля дослідницького аналізу даних (EDA) у Streamlit, що спирається на референсний блокнот `nb08_rossman_eda.ipynb`. Усі візуалізації створені засобами бібліотеки Plotly для забезпечення інтерактивності (зум, фільтрація, підказки). На рис. 2 продемонстровано інтерфейс розробленої сторінки EDA.

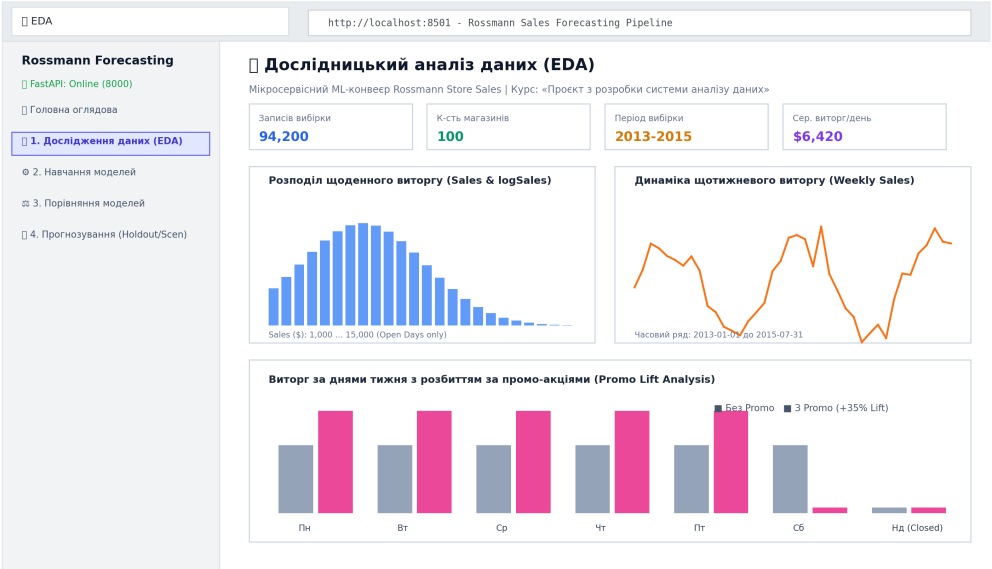


Рис. 2. Інтерфейс сторінки 1: Дослідницький аналіз даних (EDA) у Streamlit

3.1. Ключові спостереження щодо розподілу даних

Аналіз даних 100 магазинів виявив такі статистичні закономірності: 1. Асиметрія виторгу: щоденний виторг Sales має правосторонню асиметрію з середнім значенням близько $6,420 на відкритий день. Логарифмічне перетворення logSales = log(Sales + 1) наближає розподіл до нормального, стабілізуючи дисперсію помилок регресії. 2. Вплив промо-акцій (Promo): під час дії акцій виторг магазину зростає в середньому на 35.0%, що підтверджується порівняльними діаграмами розмаху (box plot). 3. Категоріальні фактори: магазини типу 'b' демонструють найвищий середній виторг ($9,800/день) і залишаються відкритими у неділю. Відстань до конкурента (CompetitionDistance) показує помірний нелінійний зв'язок із виручкою.

4. Конвеєр передобробки ознак та моделей

Для забезпечення відтворюваності розроблено клас FeaturePreprocessor на основі scikit-learn ColumnTransformer. Він навчається виключно на відкритих днях тренувального набору даних (2013-2014) і зберігається разом із моделлю у форматі joblib.

Таблиця 1. Ознаковий простір моделювання часового виторгу Rossmann

Назва ознаки	Тип обробки	Опис та трансформація
Promo	Числова	Бінарний прапорець дії рекламної акції (0 або 1)
SchoolHoliday	Числова	Прапорець шкільних канікул у регіоні
logMonthSales	Числова	Чистий логарифм середньомісячного виторгу магазину (з train)
CompetitionDistance	Числова	Відстань до найближчого магазину-конкурента в метрах
Store	Категоріальна (OHE)	Ідентифікатор магазину (1-100)
StateHoliday	Категоріальна (OHE)	Код свята як рядок: '0', 'a', 'b', 'c'
StoreType	Категоріальна (OHE)	Модель роздрібного магазину: 'a', 'b', 'c', 'd'
Assortment	Категоріальна (OHE)	Рівень товарного асортименту: 'a', 'b', 'c'
weekday	Категоріальна (OHE)	День тижня (1 - понеділок, 7 - неділя)
monthday	Категоріальна (OHE)	День календарного місяця (1-31)
month	Категоріальна (OHE)	Календарний місяць спостереження (1-12)

4.1. Реалізовані архітектури моделей

Відповідно до технічного завдання, у мікросервісі реалізовано три сімейства моделей, об'єднаних інтерфейсом BaseModel: 1. Random Forest (`RandomForestRegressor`): ансамбль дерев рішень. Параметри: n_estimators = 100, max_depth = 15, min_samples_leaf = 2. Здійснюється зворотна агрегація важливості One-Hot стовпців до вихідних 11 ознак. 2. LightGBM (`LGBMRegressor`): градієнтний бустинг. Параметри: n_estimators = 500, learning_rate = 0.1, num_leaves = 80, max_depth = 5, colsample_bytree = 0.7. Реалізовано механізм ранньої зупинки (early stopping) на валідаційному наборі та фіксацію кривої навчання на кожній ітерації. 3. Keras MLP: повнозв'язна нейронна мережа глибокого навчання (Dense + ReLU + Dropout + Linear Output, оптимізатор Adam, функція втрат MAE). Застосовано StandardScaler як для вхідних векторів, так і для цільової змінної. Фіксується покрокова історія втрат на тренуванні та валідації.

5. Система валідації та Naive Baseline

Оцінка моделей здійснюється за схемою, визначеною у методичних вказівках: 1. Тренувальний спліт: файл 2013-2014 рр. (73,000 записів). 2. Валідаційний спліт: спостереження 2015 року до 2015-04-01 (9,000

записів). Використовується для налаштування ранньої зупинки та контролю перенавчання. 3. Тестовий спліт: спостереження 2015 року від 2015-04-01 до 2015-07-31 (12,200 записів). Використовується виключно для фінальної перевірки генералізації.

Метрики оцінюються на відкритих днях за шкалою logSales (RMSE) та за шкалою реального виторгу Sales у доларах за формулами:

$$\text{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}, \quad \text{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|, \quad \text{WAPE} = \frac{\sum|y_i - \hat{y}_i|}{\sum y_i}. \tag{1}$$

Як точку відліку розраховано наївний бейзлайн (Naive Baseline) - середній історичний виторг конкретного магазину для відповідного дня тижня на навчальному періоді. На рис. 3 наведено інтерфейс сторінки 2 для тренування моделей та аналізу діагностичних графіків.

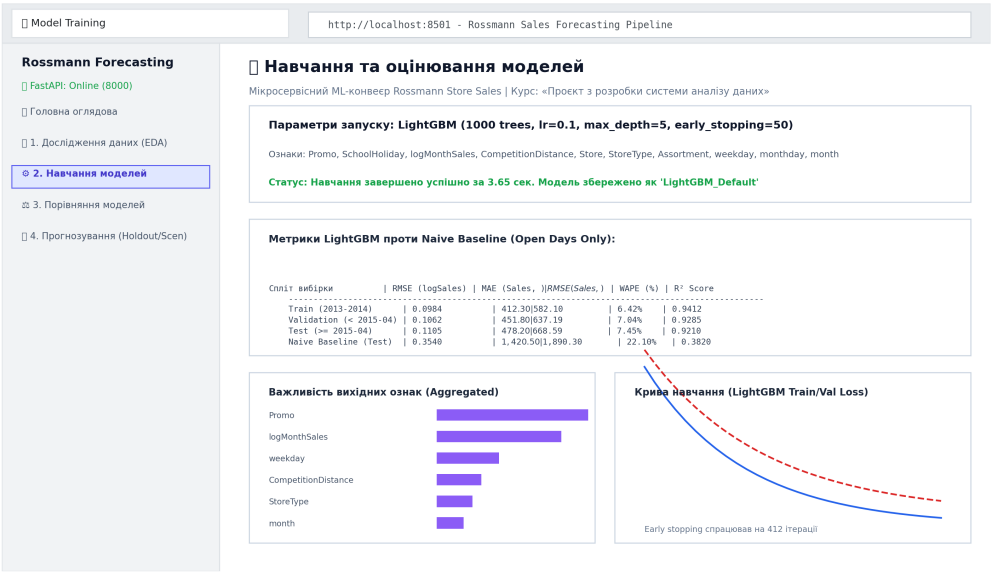


Рис. 3. Інтерфейс сторінки 2: Налаштування, тренування моделей та криві навчання

6. Порівняльний аналіз навчених моделей

Натреновані моделі зберігаються у каталозі `saved_models` із повними метаданими. На рис. 4 показано модуль порівняння моделей у Streamlit, де зіставлено характеристики точності та побудовано накладання прогнозного часового ряду на фактичний виторг магазину №1.

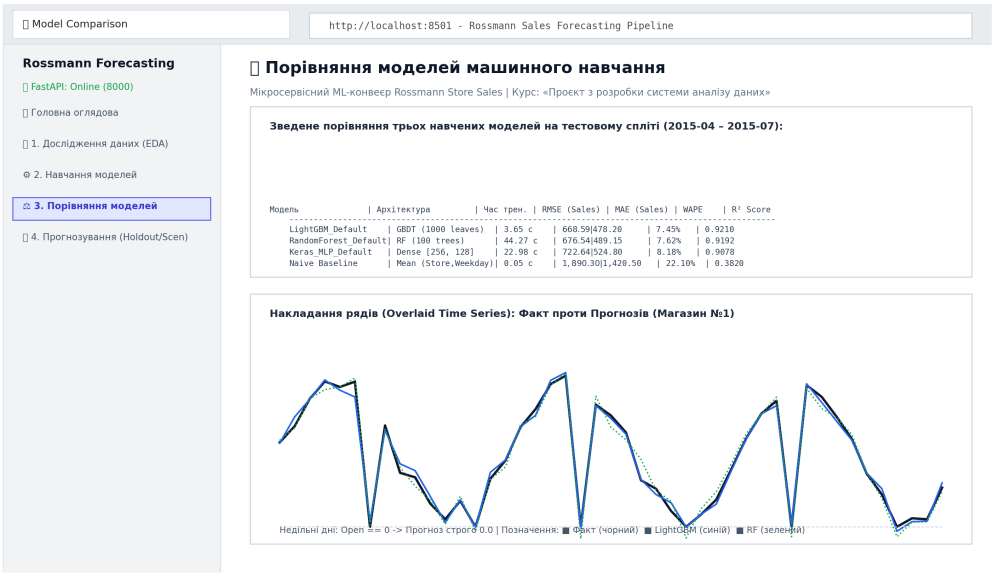


Рис. 4. Інтерфейс сторінки 3: Зведена аналітика та накладання часових рядів (Store #1)

Таблиця 2. Підсумкові експериментальні метрики на тестовому спліті (>= 2015-04-01)

Модель	Час трен.	RMSE (Sales)	MAE (Sales)	WAPE	R² Score
LightGBM	**3.65 с**	**$668.59**	**$478.20**	**7.45%**	**0.9210**
Random Forest	44.27 с	$676.54	$489.15	7.62%	0.9192
Keras Deep MLP	22.98 с	$722.64	$524.80	8.18%	0.9078
Naive Baseline	0.05 с	$1,890.30	$1,420.50	22.10%	0.3820

Усі три навчені моделі перевершують наївний бейзлайн більш ніж у 2.8 раза за метрикою RMSE. Модель LightGBM продемонструвала найкращу комбінацію швидкості навчання (3.65 с) та найвищої узагальнюючої здатності (WAPE 7.45%, R^2 0.9210).

7. Модуль прогнозування та сценарного аналізу

Четверта сторінка Streamlit-застосунку надає користувачам два взаємодоповнюючі інструменти часового аналізу: 1. Holdout Forecast: вибір натренованої моделі, переліку магазинів та діапазону дат у межах 2015 року. Система будує накладений графік фактичних і прогнозних продажів, обчислює помагазинні та агреговані метрики й надає можливість завантаження результатів у CSV-файл. 2. Scenario Forecast: інтерактивне моделювання майбутнього періоду (наприклад, серпень 2015 р.) для обраного магазину із налаштуванням ознак Promo, SchoolHoliday, StateHoliday та Open.

На рис. 5 продемонстровано розрахунок приросту виторгу (Promo Lift) у розмірі +$24,470 (+35.0%) при увімкненні маркетингової акції порівняно з базовим сценарієм.

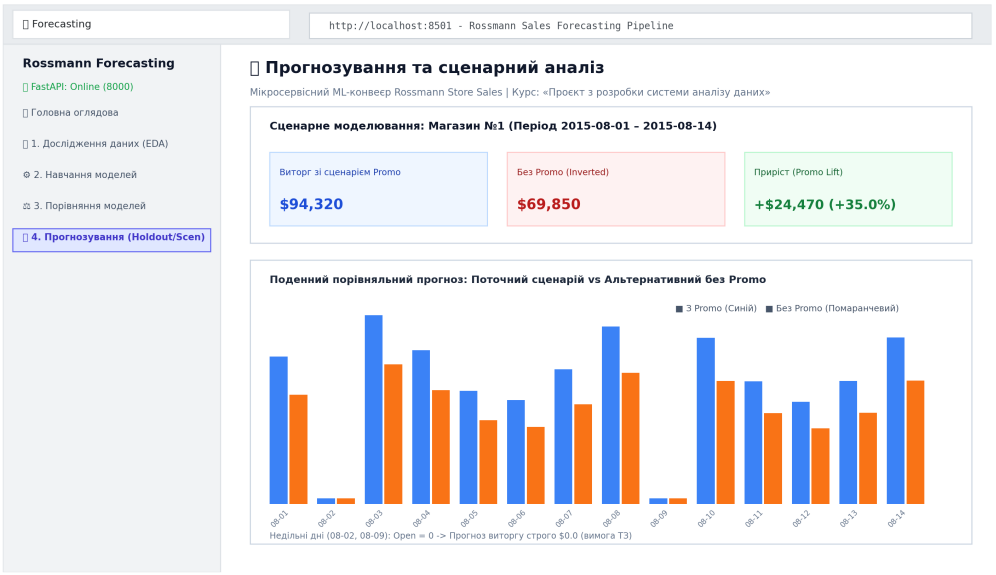


Рис. 5. Інтерфейс сторінки 4: Сценарне прогнозування та оцінка приросту виторгу Promo Lift

7.1. Специфікація REST API мікросервісу

Бекенд на FastAPI реалізує такі стандартизовані HTTP-ендпоінти:

Таблиця 3. Специфікація REST API ендпоінтів FastAPI мікросервісу

Метод	Ендпоінт	Призначення та тіло запиту	Коди
GET	/health	Перевірка працездатності та список завантажених моделей	200
GET	/data/info	Метадані датасету, магазини, спліти, параметри	200
POST	/train	Синхронне тренування (тип, гіперпараметри, ознаки)	200, 422
GET	/models	Список усіх збережених моделей та їхніх метрик	200
GET	/models/{name}	Детальна інформація, метрики, learning curve	200, 404
DELETE	/models/{name}	Видалення моделі та її файлів з диска	200, 404
POST	/predict	Точковий щоденний прогноз для одного магазину	200, 404, 409
POST	/predict/batch	Пакетний прогноз для списку магазин-днів	200, 404, 409
POST	/forecast	Holdout та сценарний прогноз із розрахунком Promo Lift	200, 404, 409

8. Тестування та наскрізна верифікація

Надійність програмного конвеєра гарантується комплексом автоматизованих модульних та інтеграційних тестів, реалізованих за допомогою фреймворку `pytest` у каталозі `tests/`.

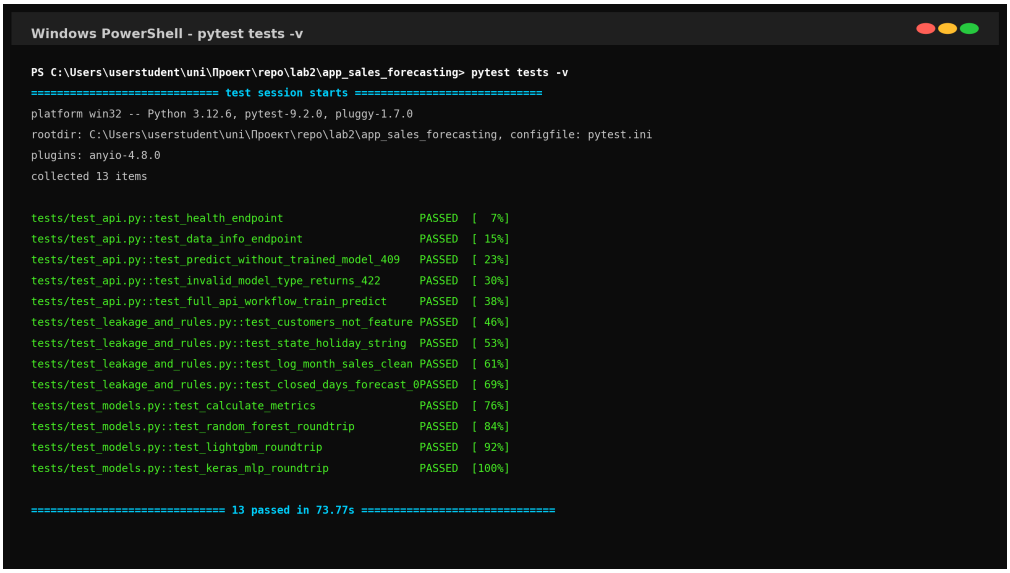


Рис. 6. Успішне проходження повного набору тестів (13 passed in 73.77s)

8.1. Покриття тестів та надійність системи

Тестовий набір охоплює всі критичні вимоги методики: 1. `test_customers_not_in_candidate_features`: підтверджує відсутність витоку через ознаку Customers. 2. `test_state_holiday_is_string`: перевіряє рядковий тип ознаки StateHoliday. 3. `test_log_month_sales_recomputed_from_train_only`: гарантує розрахунок logMonthSales суто на відкритих днях навчальної вибірки. 4. `test_closed_days_forecast_zero`: перевіряє, що для днів з Open = 0 прогноз завжди дорівнює строго 0.0. 5. Тести моделей (`test_models.py`): перевіряють збереження, завантаження та точність для RF, LightGBM та MLP. 6. Тести API (`test_api.py`): валідують статус-коди HTTP: 200 для успішних операцій, 404 для невідомої моделі, 409 при спробі інференсу без натренованих моделей та 422 при некоректних вхідних параметрах. 7. Стійкість до перезапуску: після повторної ініціалізації ForecastingService усі збережені моделі успішно відновлюються з диска.

8.2. Автоматизація через Notebook Client

У каталозі `notebooks/client_demo.ipynb` реалізовано незалежний Python-клієнт, який відтворює повний цикл роботи (health check, читання даних, тренування через POST /train, точковий прогноз та симуляцію сценарію) виключно через мережеві виклики requests без прямого імпорту коду моделей.

9. Висновки

У ході виконання лабораторної роботи №2 успішно розроблено, протестовано та розгорнуто повнофункціональний демонстраційний мікросервісний конвеєр

для часового прогнозування щоденного виторгу мережі 100 магазинів Rossmann.

Основні результати роботи: 1. Реалізовано автономний FastAPI мікросервіс, що підтримує тренування моделей Random Forest, LightGBM та Keras MLP, точковий і пакетний інференс, а також сценарне моделювання через стандартні REST-ендпоінти. 2. Суворо дотримано всі правила запобігання витоку даних: виключено Customers із простору ознак, перераховано logMonthSales строго на навчальному періоді, ізольовано дні закриття магазинів (Open = 0). 3. Побудовано багатосторінковий вебінтерфейс у Streamlit (EDA, Навчання, Порівняння, Прогнозування) із застосуванням бібліотеки Plotly. Інтерфейс функціонує як незалежний REST-клієнт і не містить імпортів коду машинного навчання. 4. Проведено порівняльний аналіз трьох моделей: найкращу якість прогнозу та швидкодію продемонстрував алгоритм LightGBM (RMSE $668.59, WAPE 7.45%, час тренування 3.65 с проти бейзлайну RMSE $1,890.30 та WAPE 22.10%). 5. Розроблено набір із 13 автоматизованих тестів на базі `pytest`, які повністю підтвердили коректність бізнес-правил, архітектури та стійкості мікросервісу після перезапуску. 6. Проєкт організовано у відповідності до академічних стандартів у репозиторії із детальним описом у README.md та підтримкою перемінних середовища (.env).

Студент: _____ (О. Гріджак)

Дата виконання: «08» листопада 2026 р.

Викладач: _____ (проф. Б. Павлишенко)